

线性方程组的数值求解

前置知识：（选主元的）高斯消去法、（选主元的）Dolittle分解、Crout分解

带状矩阵的Crout三角分解法

一个上半带宽为 s ，下半带宽为 r 的带状矩阵形似：

$$\mathbf{A} = \begin{bmatrix} a_{1,1} & \cdots & a_{1,s+1} & & & \\ \vdots & \ddots & \ddots & \ddots & & \\ a_{r+1,1} & \ddots & \ddots & \ddots & \ddots & \\ & \ddots & \ddots & \ddots & \ddots & a_{n-s,n} \\ & & \ddots & \ddots & \ddots & \vdots \\ & & & a_{n,n-r} & \cdots & a_{n,n} \end{bmatrix}$$

带状矩阵 $\mathbf{A}$ 具有特殊性，可以减少解方程、三角分解时的计算量。

若带状矩阵 $\mathbf{A}$ 的前 $n-1$ 阶顺序主子式不为 0，则有唯一的分解 $\mathbf{A} = \mathbf{L}\mathbf{U}$ ，其中 $\mathbf{L}$ 是下半带宽为 r 的单位下三角矩阵， $\mathbf{U}$ 是上半带宽为 s 的上三角矩阵：

$$\mathbf{A} = \mathbf{L}\mathbf{U} = \begin{bmatrix} 1 & & & & & \\ \vdots & \ddots & & & & \\ l_{r+1,1} & \ddots & \ddots & & & \\ & \ddots & \ddots & \ddots & & \\ & & l_{n,n-r} & \cdots & 1 \end{bmatrix} \begin{bmatrix} u_{1,1} & \cdots & u_{1,s+1} & & & \\ & \ddots & \ddots & \ddots & & \\ & & \ddots & \ddots & \ddots & \\ & & & \ddots & \ddots & u_{n-s,n} \\ & & & & \ddots & \vdots \\ & & & & & u_{n,n} \end{bmatrix}$$

选主元的三角分解由于置换矩阵 $\mathbf{P}$ 的存在，会破坏带状矩阵的特性.

三对角矩阵的追赶法

三对角矩阵是一种特殊的带状矩阵，其上半带宽、下半带宽均为 1. 三对角方程组形如 $\mathbf{A}\mathbf{x} = \mathbf{f}$.

首先，对三对角矩阵进行Crout分解：

$$\begin{bmatrix} a_1 & b_1 & & & \\ c_2 & a_2 & \ddots & & \\ & \ddots & \ddots & b_{n-1} & \\ & & c_n & a_n & \end{bmatrix} = \begin{bmatrix} \alpha_1 & & & & \\ \gamma_2 & \alpha_2 & & & \\ & \ddots & \ddots & & \\ & & \gamma_n & \alpha_n & \end{bmatrix} \begin{bmatrix} 1 & \beta_1 & & & \\ & 1 & \ddots & & \\ & & 1 & \beta_{n-1} & \\ & & & 1 \end{bmatrix}$$

通过右侧两矩阵相乘并与原矩阵对应，得到如下分解公式：

$$\begin{cases} \gamma_i = c_i, & i = 2, \dots, n \\ \alpha_i = a_i - c_i \beta_{i-1}, & i = 1, \dots, n \\ \beta_i = \frac{b_i}{\alpha_i}, & i = 1, \dots, n-1 \end{cases}$$

其中 $c_1 = 0$, $\beta_n = 0$.

通过分解得到各 $\alpha_i, \beta_i, \gamma_i$ 后，顺序计算 y_i 并逆序计算 x_i ：

$$\begin{cases} y_i = \frac{f_i - c_i y_{i-1}}{\alpha_i}, & i = 1, \dots, n \\ x_i = y_i - \beta_i x_{i+1}, & i = n, \dots, 1 \end{cases}$$

即可得到原三对角线性方程组的解。

最速下降法

最速下降法的“数值格式”、“收敛条件”、“误差估计方法”较为重要。

首先定义二次泛函

$$\begin{aligned} \varphi(\mathbf{x}) &= \frac{1}{2}(\mathbf{Ax}, \mathbf{x}) - (\mathbf{b}, \mathbf{x}) \\ &= \frac{1}{2}\mathbf{x}^T \mathbf{Ax} - \mathbf{x}^T \mathbf{b} \end{aligned}$$

不难有

$$\begin{aligned} \nabla \varphi &= \left(\frac{\partial \varphi}{\partial x_1}, \frac{\partial \varphi}{\partial x_2}, \dots, \frac{\partial \varphi}{\partial x_n} \right) \\ &= \mathbf{Ax} - \mathbf{b} \end{aligned}$$

线性方程组 $\mathbf{Ax} = \mathbf{b}$ 的解 $\mathbf{x}^*$ 即为二次泛函 $\varphi(\mathbf{x})$ 的最小值。

在下降过程中，每一步均沿着下降速度最快的方向前进（即负梯度方向），找到 $\varphi(\mathbf{x})$ 的最小值即可得到原方程组的解。

考虑更新公式

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{r}^{(k)}$$

其中 α_k 为第 k 步的步长， $\mathbf{r}^{(k)}$ 为负梯度方向 $\mathbf{r}^{(k)} = -\mathbf{Ax}^{(k)} + \mathbf{b}$ 。

考虑

$$\begin{aligned}\varphi(\mathbf{x}^{(k+1)}) &= \varphi(\mathbf{x}^{(k)} + \alpha_k \mathbf{r}^{(k)}) \\ &= \varphi(\mathbf{x}^{(k)}) - \left(\alpha_k (\mathbf{r}^{(k)}, \mathbf{r}^{(k)}) - \frac{\alpha_k^2}{2} (\mathbf{A} \mathbf{r}^{(k)}, \mathbf{r}^{(k)}) \right)\end{aligned}$$

最小化 $\varphi(\mathbf{x}^{(k+1)})$, 即

$$\arg \max_{\alpha_k} \left(\alpha_k (\mathbf{r}^{(k)}, \mathbf{r}^{(k)}) - \frac{\alpha_k^2}{2} (\mathbf{A} \mathbf{r}^{(k)}, \mathbf{r}^{(k)}) \right)$$

得

$$\alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}{(\mathbf{A} \mathbf{r}^{(k)}, \mathbf{r}^{(k)})}$$

最速下降法的数值格式

从而可以得到最速下降法:

1. 取 $\mathbf{x}^{(0)} \in \mathbb{R}^n$, $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(0)}$;
2. $k = 0, 1, \dots$;
3. 计算步长 $\alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}{(\mathbf{A} \mathbf{r}^{(k)}, \mathbf{r}^{(k)})}$;
4. 更新 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{r}^{(k)}$;
5. 计算新方向 $\mathbf{r}^{(k+1)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A} \mathbf{r}^{(k)}$
6. 若 $\frac{\|\mathbf{r}^{(k+1)}\|}{\|\mathbf{r}^{(0)}\|} < \varepsilon$, 则输出 $\mathbf{x}^* = \mathbf{x}^{(k+1)}$, 否则转3.

最速下降法的收敛性

若 $\mathbf{A}$ 对称正定, 则有

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$$

最速下降法的误差

若最速下降法收敛, 且 $\mathbf{A}$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$, 则有误差

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\|_{\mathbf{A}} \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|_{\mathbf{A}}$$

共轭梯度法

共轭梯度法的“数值格式”、“收敛条件”、“误差估计方法”较为重要.

A-共轭

若 $\mathbf{A}$ 对称正定, $(\mathbf{x}, \mathbf{A}\mathbf{y}) = 0$, 则称 $\mathbf{x}$ 和 $\mathbf{y}$ 是A-正交或A-共轭的.

参考施密特正交化的原理, 构造A-共轭向量组 $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(n-1)}$.

首先, 取 $\tilde{\mathbf{p}}^{(0)} = \mathbf{r}^{(0)}$, $\tilde{\mathbf{p}}^{(1)} = \mathbf{r}^{(1)}$, 有

$$\begin{aligned}\mathbf{p}^{(0)} &= \tilde{\mathbf{p}}^{(0)} \\ \mathbf{p}^{(1)} &= \tilde{\mathbf{p}}^{(1)} - u_{10}\mathbf{p}^{(0)} \\ \mathbf{p}^{(k)} &= \tilde{\mathbf{p}}^{(k)} - \sum_{i=0}^{k-1} u_{ki}\mathbf{p}^{(i)}\end{aligned}$$

由A-共轭的定义, 有

$$\begin{aligned}(\mathbf{p}^{(1)}, \mathbf{A}\mathbf{p}^{(0)}) &= (\mathbf{r}^{(1)} - u_{10}\mathbf{p}^{(0)}, \mathbf{A}\mathbf{p}^{(0)}) \\ &= (\mathbf{r}^{(1)}, \mathbf{A}\mathbf{p}^{(0)}) - u_{10}(\mathbf{p}^{(0)}, \mathbf{A}\mathbf{p}^{(0)}) \\ &= 0\end{aligned}$$

故

$$u_{10} = \frac{(\mathbf{r}^{(1)}, \mathbf{A}\mathbf{p}^{(0)})}{(\mathbf{p}^{(0)}, \mathbf{A}\mathbf{p}^{(0)})}$$

其他系数同理.

综上, 得到A-共轭向量组, 其中

$$\mathbf{p}^{(k)} = \mathbf{r}^{(k)} - \sum_{i=0}^{k-1} \frac{(\mathbf{r}^{(k)}, \mathbf{A}\mathbf{p}^{(i)})}{(\mathbf{p}^{(i)}, \mathbf{A}\mathbf{p}^{(i)})} \mathbf{p}^{(i)}$$

共轭梯度法的数值格式

从而可以得到共轭梯度法:

1. 取 $\mathbf{x}^{(0)} \in \mathbb{R}^n$, $\mathbf{r}^{(0)} = \mathbf{p}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$;
2. $k = 0, 1, \dots$;
3. 计算步长 $\alpha_k = \frac{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}{(\mathbf{A}\mathbf{p}^{(k)}, \mathbf{p}^{(k)})}$;
4. 更新 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}$;

5. 计算新残差 $\mathbf{r}^{(k+1)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A}\mathbf{p}^{(k)}$
6. 若 $\frac{\|\mathbf{r}^{(k+1)}\|}{\|\mathbf{r}^{(0)}\|} < \varepsilon$, 则输出 $\mathbf{x}^* = \mathbf{x}^{(k+1)}$;
7. $\beta_k = \frac{(\mathbf{r}^{(k+1)}, \mathbf{r}^{(k+1)})}{(\mathbf{r}^{(k)}, \mathbf{r}^{(k)})}$;
8. $\mathbf{p}^{(k+1)} = \mathbf{r}^{(k)} + \beta_k \mathbf{p}^{(k)}$, 转3.

共轭梯度法的收敛性

若 $\mathbf{A}$ 对称正定, 则共轭梯度法最多 n 步即可找到精确解 $\mathbf{x}^*$.

共轭梯度法的误差

若共轭梯度法收敛, 则有误差

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\|_{\mathbf{A}} \leq 2 \left(\frac{\sqrt{K} - 1}{\sqrt{K} + 1} \right)^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|_{\mathbf{A}}$$

其中, $K = \kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2$.

矩阵特征值和特征向量的计算

Jacobi法

要求矩阵必须是实对称方阵, 优点是可以求所有的特征和对应的特征向量.

Jacobi方法总是收敛, 稳定性好; 但会破坏矩阵的原有结构, 计算费时 (Jacobi方法几乎不太能手算) .

QR法

Schur分解

有矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则存在正交矩阵 $\mathbf{Q} \in \mathbb{R}^{n \times n}$, 使得

$$\mathbf{Q}^T \mathbf{A} \mathbf{Q} = \begin{bmatrix} \mathbf{R}_{11} & \mathbf{R}_{12} & \cdots & \mathbf{R}_{1m} \\ & \mathbf{R}_{22} & \cdots & \mathbf{R}_{2m} \\ & & \ddots & \vdots \\ & & & \mathbf{R}_{mm} \end{bmatrix}$$

其中 $\mathbf{R}_{jj}$ 是实数或有一堆共轭特征值的2阶方阵.

其中, $\mathbf{Q}^T \mathbf{A} \mathbf{Q}$ 称为矩阵 $\mathbf{A}$ 的Schur标准形.

QR分解

若 $\mathbf{A}$ 是 n 阶实方阵, 则 $\mathbf{A}$ 可以分解为正交矩阵 $\mathbf{Q}$ 和上三角矩阵 $\mathbf{R}$ 之积.

利用QR分解求矩阵特征值的方法如下:

1. $\mathbf{A}_1 = \mathbf{A}$;
2. $k = 1, 2, \dots$;
3. $\mathbf{A}_k = \mathbf{Q}_k \mathbf{R}_k$;
4. $\mathbf{A}_{k+1} = \mathbf{R}_k \mathbf{Q}_k = (\mathbf{Q}_k^T \mathbf{A} \mathbf{Q}_k)$.

Householder矩阵

设 $\mathbf{v}$ 为 n 维单位向量, $\mathbf{v}^T \mathbf{v} = 1$, 可以得到Householder矩阵 $\mathbf{H} = \mathbf{I} - 2\mathbf{v}\mathbf{v}^T$.

Householder矩阵 $\mathbf{H}$ 是正交矩阵.

有非零向量 $\mathbf{s}$, 单位向量 $\mathbf{e}$, 存在一个Householder矩阵 $\mathbf{H}$, 使得 $\mathbf{H}\mathbf{s} = \alpha\mathbf{e}$, 其中 $\alpha \in \mathbb{R}$, $|\alpha| = \sqrt{\mathbf{s}^T \mathbf{s}}$.

通过构造向量 $\mathbf{v} = \frac{1}{\rho}(\mathbf{s} - \alpha\mathbf{e})$, 其中 $\rho = \sqrt{((\mathbf{s} - \alpha\mathbf{e}))^T((\mathbf{s} - \alpha\mathbf{e}))}$

通过Householder矩阵进行QR分解的流程如下:

1. 令 $\mathbf{s}_1 = (a_{11}, a_{12}, \dots, a_{1n})^T$, $c_1 = -\text{sgn}(a_{11})\sqrt{\mathbf{s}_1^T \mathbf{s}_1}$ ($a_{11} = 0$ 时, $c_1 = \sqrt{\mathbf{s}_1^T \mathbf{s}_1}$);
2. 取 $\mathbf{u}_1 = \mathbf{s}_1 - c_1\mathbf{e}_1$, $\mathbf{H}_1 = \mathbf{I} - \frac{2\mathbf{u}_1\mathbf{u}_1^T}{\mathbf{u}_1^T \mathbf{u}_1}$;
3. 此时有 $\mathbf{H}_1\mathbf{s}_1 = c_1\mathbf{e}_1 = (c_1, 0, \dots, 0)^T$;
4. 有 $\mathbf{A}_2 = \mathbf{H}_1\mathbf{A}_1 = \begin{bmatrix} c_1 & a_{12}^{(2)} & \dots & a_{1n}^{(2)} \\ 0 & a_{22}^{(2)} & \dots & a_{2n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2}^{(2)} & \dots & a_{nn}^{(2)} \end{bmatrix}$;
5. 若 $a_{i1} = 0$ ($i = 2, 3, \dots, n$) 全为0, 则取 $\mathbf{H}_1 = \mathbf{I}$;
6. 设 $a_{i2} = 0$ ($i = 3, \dots, n$) 不全为0;
7. 令 $\mathbf{s}_2 = (0, a_{22}^{(2)}, \dots, a_{n2}^{(2)})^T$, $c_2 = -\text{sgn}(a_{22})\sqrt{\mathbf{s}_2^T \mathbf{s}_2}$ ($a_{22} = 0$ 时, $c_2 = \sqrt{\mathbf{s}_2^T \mathbf{s}_2}$);
8. 取 $\mathbf{u}_2 = \mathbf{s}_2 - c_2\mathbf{e}_2$, $\mathbf{H}_2 = \mathbf{I} - \frac{2\mathbf{u}_2\mathbf{u}_2^T}{\mathbf{u}_2^T \mathbf{u}_2}$;
9. 此时有 $\mathbf{H}_2\mathbf{s}_2 = c_2\mathbf{e}_2 = (0, c_2, \dots, 0)^T$;

10. 有 $\mathbf{A}_2 = \mathbf{H}_2 \mathbf{A}_1 = \begin{bmatrix} c_1 & a_{12}^{(2)} & \cdots & a_{1n}^{(2)} \\ 0 & c_2 & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn}^{(2)} \end{bmatrix}$;
11. 若 $a_{i2} = 0$ ($i = 3, \dots, n$) 全为0, 则取 $\mathbf{H}_2 = \mathbf{I}$;
12. 重复直到 $\mathbf{A}_n = \mathbf{H}_{n-1} \mathbf{H}_{n-2} \cdots \mathbf{H}_1 \mathbf{A}$ 是上三角矩阵;
13. $\mathbf{A} = \mathbf{H}_1 \mathbf{H}_2 \cdots \mathbf{H}_{n-1} \mathbf{A}_n$;
14. 令 $\mathbf{Q} = \mathbf{H}_1 \mathbf{H}_2 \cdots \mathbf{H}_{n-1}$, $\mathbf{R} = \mathbf{A}_n$, 有 $\mathbf{A} = \mathbf{QR}$.

改进QR法

为了减少QR法大量矩阵相乘带来的计算量提出, 利用 $\mathbf{Q}_{r+1} = \mathbf{Q}_r \mathbf{u}_r$ 与 $\mathbf{A}_{r+1} = \mathbf{H}_r \mathbf{A}_r$ 与 $\mathbf{H}$ 的计算公式, 将矩阵相乘的迭代过程化为矩阵向量、向量向量乘.

非线性方程和方程组的求解

Steffensen加速方法

为了加速迭代法的收敛, Steffensen加速方法从 x_k 出发, 考虑两次迭代:

$$\begin{aligned} x_{k+1} &= \varphi(x_k) \\ x_{k+2} &= \varphi(x_{k+1}) \end{aligned}$$

可以得到

$$\begin{aligned} x_{k+1} - s &= \varphi(x_k) - \varphi(s) = \varphi'(\xi_k)(x_k - s) \\ x_{k+2} - s &= \varphi(x_{k+1}) - \varphi(s) = \varphi'(\xi_{k+1})(x_{k+1} - s) \end{aligned}$$

考虑 x 在 s 附近, 有 $\varphi'(\xi_k) \approx \varphi'(\xi_{k+1})$, 有

$$\frac{x_{k+1} - s}{x_k - s} \approx \frac{x_{k+2} - s}{x_{k+1} - s}$$

故得到

$$s \approx x_k - \frac{(x_{k+1} - x_k)^2}{x_{k+2} - 2x_{k+1} + x_k}$$

记 $y_k = x_{k+1}$, $z_k = x_{k+2}$, 有Steffensen加速法:

$$\begin{cases} y_k = \varphi(x_k) \\ z_k = \varphi(y_k) \\ x_{k+1} = x_k - \frac{(y_k - x_k)^2}{z_k - 2y_k + x_k} \end{cases}, k = 0, 1, \dots$$

设 $s = \varphi(s)$, $\varphi(x)$ 在 $(s - \delta, s + \delta)$ 内有二阶导数, 且 $\varphi'(s) \neq 1$, 则 $\exists \delta > 0, x_0 \in [s - \delta, s + \delta], x_0 \neq s$, $\{x_k\}$ 至少二阶收敛到 s .

原迭代发散时, Steffensen方法依旧可能收敛.

Newton法

对于非线性方程组

$$\begin{cases} f_1(x_1, x_2, \dots, x_n) = 0 \\ f_2(x_1, x_2, \dots, x_n) = 0 \\ \vdots \\ f_n(x_1, x_2, \dots, x_n) = 0 \end{cases}$$

令 $\mathbf{X} = (x_0, x_1, \dots, x_n)^T$, 原方程化为

$$F(\mathbf{X}) = (f_1(\mathbf{X}), f_2(\mathbf{X}), \dots, f_n(\mathbf{X}))^T = \mathbf{0}$$

函数 $f_i(\mathbf{X})$ 的导数为 $f'_i(\mathbf{X}) = \left(\frac{\partial f_i(\mathbf{X})}{\partial x_1}, \frac{\partial f_i(\mathbf{X})}{\partial x_2}, \dots, \frac{\partial f_i(\mathbf{X})}{\partial x_n} \right)^T$

故有 $F(\mathbf{X})$ 的导数

$$F'(\mathbf{X}) = \left[\frac{\partial f_i(\mathbf{X})}{\partial x_j} \right]_{n \times n} = \begin{bmatrix} \frac{\partial f_1(\mathbf{X})}{\partial x_1} & \frac{\partial f_1(\mathbf{X})}{\partial x_2} & \dots & \frac{\partial f_1(\mathbf{X})}{\partial x_n} \\ \frac{\partial f_2(\mathbf{X})}{\partial x_1} & \frac{\partial f_2(\mathbf{X})}{\partial x_2} & \dots & \frac{\partial f_2(\mathbf{X})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n(\mathbf{X})}{\partial x_1} & \frac{\partial f_n(\mathbf{X})}{\partial x_2} & \dots & \frac{\partial f_n(\mathbf{X})}{\partial x_n} \end{bmatrix}$$

若

$$\lim_{\mathbf{h} \rightarrow \mathbf{0}} \frac{\|F(\mathbf{X} + \mathbf{h}) - F(\mathbf{X}) - \mathbf{A}(\mathbf{X})\mathbf{h}\|}{\|\mathbf{h}\|} = 0$$

则称 F 在 $\mathbf{X}$ 处可微, 其导数为 $\mathbf{A}(\mathbf{X})$.

对于非线性方程组的牛顿法, 同样考虑Taylor展开:

$$f_i(\mathbf{X}) \approx f_i(\mathbf{X}^{(k)}) + \sum_{j=1}^n \frac{\partial f_i(\mathbf{X}^{(k)})}{\partial x_j} (x_j - x_j^{(k)}), i = 1, 2, \dots, n$$

得迭代格式

$$\mathbf{X}^{(k+1)} = \mathbf{X}^{(k)} - F'(\mathbf{X}^{(k)})^{-1} F(\mathbf{X}^{(k)})$$

为了避免求矩阵的逆，作如下变形：

$$F'(\mathbf{X}^{(k)})(\mathbf{X}^{(k+1)} - \mathbf{X}^{(k)}) = -F(\mathbf{X}^{(k)})$$

令 $\Delta \mathbf{X}^{(k)} = \mathbf{X}^{(k+1)} - \mathbf{X}^{(k)}$ ，则每轮迭代只需要解以下方程组：

$$F'(\mathbf{X}^{(k)})\Delta \mathbf{X}^{(k)} = -F(\mathbf{X}^{(k)})$$

并利用 $\mathbf{X}^{(k+1)} = \mathbf{X}^{(k)} + \Delta \mathbf{X}^{(k)}$ 更新即可。

若牛顿迭代法解非线性方程组收敛，则其收敛速度至少是超线性的。

离散牛顿法

为了避免对原函数求导，使用

$$\frac{\partial f_i}{\partial x_j} = \frac{f_i(\mathbf{X}^{(k)} + \mathbf{h}_i^{(k)} \mathbf{e}_j) - f_i(\mathbf{X}^{(k)})}{\mathbf{h}_i^{(k)}}$$

近似 $F'(\mathbf{X}^{(k)})$ 中的元素. 称为离散牛顿法。

函数插值和逼近

样条插值

对分划 $\pi : a = x_0 < x_1 < \dots < x_{n-1} < x_n = b$ ，若

$$\begin{cases} s(x) \text{ 在每个子区间 } [x_i, x_{i+1}] \text{ 上是次数不高于 } k \text{ 的多项式;} \\ s(x) \text{ 在 } [a, b] \text{ 上有 } k-1 \text{ 阶连续导数.} \end{cases}$$

则 $s(x)$ 是 k 次多项式样条函数. 常取 $k = 3$.

设 $s(x)$ 共 n 个区间，每个区间均是形如 $a_3 x^3 + a_2 x^2 + a_1 x^1 + a_0$ 的多项式函数，待定系数共 $4n$ 个. 以下约束可以确定 $4n - 2$ 个方程：

1. $s(x)$ 连续, $s_i(x_i) = s_{i-1}(x_i)$ 可提供 $n - 1$ 个方程;
2. $s'(x)$ 连续, $s'_i(x_i) = s'_{i-1}(x_i)$ 可提供 $n - 1$ 个方程;
3. $s''(x)$ 连续, $s''_i(x_i) = s''_{i-1}(x_i)$ 可提供 $n - 1$ 个方程;
4. $n - 1$ 个插值节点条件 $s(x_i) = f(x_i)$ 可提供 $n + 1$ 个方程;

最后两个条件由边界条件确定.

1. 给定两个边界的二阶导数. 特别地, 如果两个边界的二阶导数均为0, 则称为自然样条函数;
2. 给定两个边界的一阶导数;
3. $f(x)$ 是以 $x_n - x_0$ 为周期的函数同样可以确定边界条件.

第一、第二边界条件可以混合使用.

三角插值与傅里叶变换

**以下使用 i 作为虚数单位, j 不是虚数单位. **

取 $\phi = \text{span}\{1, \sin x, \cos x, \sin 2x, \cos 2x, \dots, \sin nx, \cos nx\}$, 求

$$s_n(x) = \frac{a_0}{2} + \sum_{j=1}^n (a_j \cos jx + b_j \sin jx)$$

使

$$s_n(x_l) = f(x_l) \quad \left(x_l = \frac{2\pi l}{N}\right)$$

由三角函数系的正交性可以得到

$$\begin{cases} a_j = \frac{2}{N} \sum_{l=0}^{N-1} f\left(\frac{2\pi l}{N}\right) \cos j \frac{2\pi l}{N} \\ b_j = \frac{2}{N} \sum_{l=1}^{N-1} f\left(\frac{2\pi l}{N}\right) \sin j \frac{2\pi l}{N} \end{cases}$$

二元函数插值

$$P_{nm}(x, y) = \sum_{k=0}^n \sum_{r=0}^m l_k(x) \tilde{l}_r(y) f(x_k, y_r)$$

其中 $l(\cdot)$ 为Lagrange基函数.

连续函数的最优平方逼近

定义函数的范数：

$$\|f - p\|_2 = \sqrt{\int_a^b [f - p]^2 \, dx}$$

则 $p_n^* \in H_n$ ，使得

$$\|f - p_n^*\|_2 = \sqrt{\int_a^b [f - p_n^*]^2 \, dx} = \inf_{p \in H_n} \|f - p\|_2$$

定义函数的内积：

$$(f, g) = \int_a^b \rho(x) f(x) g(x) \, dx$$

其中 $\rho(x)$ 为权函数.

最优平方逼近即找到 p^* ，使得 $(f - p^*, f - p^*) = \min_{p \in H_n} (f - p, f - p)$.

故对于函数系，有

$$(f - p^*, \varphi_j) = (f, \varphi_j) - \sum_{k=0}^n c_k^* (\varphi_k, \varphi_j) = 0$$

于是有方程

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} c_0^* \\ c_1^* \\ \vdots \\ c_n^* \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{bmatrix}$$

该方程称为法方程或正规方程.

若 $\varphi_0, \varphi_1, \dots, \varphi_n$ 相互正交，则有：

$$c_j^* = \frac{(\varphi_j, f)}{(\varphi_j, \varphi_j)}$$

数值积分

Newton-Cotes公式

复化求积法需要格外关注 $n = 1, 2, 4$ 的Newton-Cotes公式:

$n = 1$ 的Newton-Cotes公式

$$\int_a^b f(x) dx \approx \frac{b-a}{2}(f(a) + f(b))$$

$$R_1 = -\frac{(b-a)^3}{12} f''(\eta)$$

$n = 2$ 的Newton-Cotes公式

$$\int_a^b f(x) dx \approx \frac{b-a}{6} \left(f(a) + f(b) + 4f\left(\frac{a+b}{2}\right) \right)$$

$$R_2 = -\frac{(b-a)^5}{2880} f^{(4)}(\eta)$$

$n = 4$ 的Newton-Cotes公式

$$\int_a^b f(x) dx \approx \frac{b-a}{90} \left(7f(a) + 32f\left(\frac{3a+b}{4}\right) + 12f\left(\frac{a+b}{2}\right) + 32f\left(\frac{a+3b}{4}\right) + 7f(b) \right)$$

$$R_4 = -\frac{(b-a)^7}{1935360} f^{(6)}(\eta)$$

复化求积法

复化求积法的主要思想是将求积区间划分为一个分划, 并对分划上的每一个区间使用求积公式并求和. 复化求积法的余项由原求积法的余项得到, 而原求积法的余项可以通过Taylor展开得到.

取等距节点 $x_k = a + kh$, $h = \frac{b-a}{n}$, 复化梯形公式为

$$\int_a^b f(x) dx = \frac{h}{2} \left(f(a) + f(b) + 2 \sum_{k=1}^{n-1} f(a + kh) \right) - \frac{h^2}{12} (b-a) f''(\eta)$$

Richardson外推法

若 $F^* - F(h) = a_1 h^{p_1} + a_2 h^{p_2} + \cdots + a_k h^{p_k} + \cdots = \mathcal{O}(h^{p_1})$, 其中 $p_k > p_{k-1} > \cdots > p_1 > 0$.

使用 qh 代替 h , q 满足 $1 - q^{p_1} \neq 0$, 有

$$F^* - F(qh) = a_1(qh)^{p_1} + \cdots + a_k(qh)^{p_k} + \cdots$$

与

$$q^{p_1} F^* - q^{p_1} F(h) = a_1(qh)^{p_1} + a_2 q^{p_1} h^{p_2} + \cdots$$

两式相减，有

$$F^* = \frac{F(qh) - q^{p_1} F(h)}{1 - q^{p_1}} = a_2 \frac{q^{p_2} - q^{p_1}}{1 - q^{p_1}} h^{p_2} + \cdots = \mathcal{O}(h^{p_2})$$

称以上过程为一次外推，记为

$$F_1(h) = \frac{F_0(qh) - q^{p_1} F_0(h)}{1 - q^{p_1}}$$

Romberg方法

设 $T(h) = \frac{h}{2} \left(f(a) + f(b) + 2 \sum_{i=1}^{n-1} f(x_i) \right)$ ，为复化梯形公式，截断误差为 $\mathcal{O}(h^2)$

Romberg方法为

$$\begin{cases} T_0(h) = T(h) \\ T_k(h) = \frac{2^{2k} T_{k-1}(\frac{h}{2}) - T_{k-1}(h)}{2^{2k} - 1} \end{cases}$$

其中， $T_k(h)$ 的截断误差为 $\mathcal{O}(h^{2(k+1)})$.

此时， $T_1(h)$ 即为复化Simpson公式； $T_2(h)$ 为复化Cotes公式， $T_3(h)$ 为复化Romberg公式.

常微分方程初值问题数值解法

线性多步法

线性多步法的一般形式为

$$\sum_{i=0}^k \alpha_i y_{n+1} = h \sum_{i=0}^k \beta_i f_{n+1}$$

其中 $\alpha_k = 1$.

若 $\beta_k \neq 0$ ，则称为隐式格式，否则，称为显式格式. 余项为

$$R_{n+k} = \sum_{i=0}^k (\alpha_i y(x_n + ih) - h\beta_i f(x_{n+i}, y(x_{n+i})))$$

可以通过待定系数法构造线性多步法格式, 即使用Taylor展开对 $y(x + ih)$ 和 $y'(x + ih)$ 进行展开, 并利用余项公式进行计算. 得到

$$R = c_0 y(x) + c_1 h y'(x) + \cdots + c_r h^r y^{(r)}(x) + \cdots$$

并令 c_i 尽可能多为0.

绝对稳定性与绝对稳定域

称线性常系数微分方程

$$y' = \lambda y$$

为模型方程. 线性多步法解模型方程有:

$$\sum_{i=0}^k \alpha_i y_{n+1} = \mu \sum_{i=0}^k \beta_i f_{n+1}, \quad \mu = h\lambda$$

考虑特征根方程

$$\underbrace{\sum_{i=0}^k \alpha_i y_{n+1}}_{\rho(\xi)} - \mu \underbrace{\sum_{i=0}^k \beta_i f_{n+1}}_{\sigma(\xi)} = 0$$

若 $\|\xi_1, \xi_2, \dots\|_{\infty} < 1$, 则线性多步法是稳定的.

可以使用如下定理进行判断:

实系数 k 次代数方程 $\sum_{j=0}^k \alpha_j \xi^j = 0 (\alpha_k > 0)$ 的所有根按模小于1的必要条件是下列不等式同时成立:

1. $|\alpha_0| < \alpha_k$;
2. $\sum_{j=0}^k \alpha_j > 0$;
3. $\sum_{j=0}^k (-1)^{k-j} \alpha_j > 0$;

若 $k = 2$, 则成为充分必要条件.